Detecção de Anomalias em Cartões de Pagamento do Governo Federal Brasileiro *

Iury G. Godoy[1], Gabriel H. Silva[2], Gabriel R. Ibituruna[3], Matheus L. Silva[4]

[1] Faculdade de Computação – Universidade Federal de Uberlândia (UFU)

Caixa Postal 593 – 38.400-902 – Minas Gerais – MG – Brasil

[2] Faculdade de Computação – Universidade Federal de Uberlândia (UFU)

Caixa Postal 593 – 38.400-902 – Minas Gerais – MG – Brasil

[3] Faculdade de Computação – Universidade Federal de Uberlândia (UFU)

Caixa Postal 593 – 38.400-902 – Minas Gerais – MG – Brasil

[4] Faculdade de Computação – Universidade Federal de Uberlândia (UFU)

Caixa Postal 593 – 38.400-902 – Minas Gerais – MG – Brasil

iury.godoy@ufu.br, gabriel.hnr@ufu.br, gabriel.ibituruna@ufu.br, matheus.luciano@ufu.br

Abstract. *This technical report describes the development of a data mining system for detecting anomalies in carriers made via Federal Government Purchase Cards (CPGF) between 2022 and 2026. Utilizing records from the Transparency Portal, the project applies clustering algorithms to identify carriers that deviate from standard public spending patterns. The goal is to provide an automated auditing tool capable of flagging potential misuse of public funds, thereby enhancing governmental oversight mechanisms.*

Resumo. *Este relatório técnico descreve o desenvolvimento de um sistema de mineração de dados para a detecção de anomalias nos portadores do Cartão de Pagamento do Governo Federal (CPGF) entre 2022 e 2026. Utilizando dados do Portal da Transparência, o projeto aplica algoritmos de agrupamento para identificar portadores que se desviam dos padrões normais de consumo público. O objetivo é fornecer uma ferramenta de auditoria automatizada capaz de sinalizar indícios de uso indevido de fundos, aprimorando os mecanismos de fiscalização governamental.*

1. Introdução

O Cartão de Pagamento do Governo Federal (CPGF) foi criado com o objetivo de facilitar a compra de materiais e a contratação de serviços pelos órgãos da administração pública federal no Brasil. A proposta é tornar essas operações mais rápidas e menos burocráticas quando comparadas aos métodos tradicionais de compras governamentais. Mesmo representando um avanço importante do ponto de vista administrativo e tecnológico, ainda existe a possibilidade de uso inadequado do sistema, o que pode resultar no emprego

---

*Adaptação para OpenOffice.org 1.1 feita por Roland Teodorowitsch (roland@ulbra.tche.br) em 29 mar. 2005.

indevido de recursos públicos ou em despesas que não estejam totalmente alinhadas com a legislação vigente.

Nos últimos anos, o mercado de cartões no Brasil tem crescido de forma significativa, movimentando volumes financeiros cada vez maiores. Esse aumento naturalmente traz novos desafios para o monitoramento dos portadores e para a identificação de possíveis irregularidades. No caso específico do CPGF, a grande quantidade de registros financeiros gerados dificulta a análise manual das informações, tornando mais complexo identificar padrões suspeitos ou comportamentos incomuns nos gastos realizados.

Atualmente, o Portal da Transparência do Governo Federal disponibiliza dados detalhados sobre as despesas realizadas por meio do CPGF. No entanto, essas informações geralmente são apresentadas em formatos técnicos e descritivos, sem o apoio de ferramentas automatizadas capazes de destacar possíveis irregularidades. Essa limitação acaba dificultando o exercício do controle social, já que grande parte da população não possui conhecimento técnico ou ferramentas analíticas suficientes para interpretar esses dados e identificar possíveis problemas de maneira clara e acessível.

Diante desse cenário, o desenvolvimento de estudos que utilizem métodos automatizados de análise de dados se torna especialmente relevante. A aplicação de técnicas de ciência de dados pode ajudar a transformar grandes volumes de informações financeiras em conhecimento útil para o monitoramento e a fiscalização dos gastos públicos. Dessa forma, torna-se possível fortalecer tanto a transparência quanto os mecanismos de contabilidade na administração pública.

Do ponto de vista técnico, a principal preocupação relacionada ao uso do CPGF não está necessariamente associada a fraudes externas comuns, como roubo ou clonagem de cartões. O foco está principalmente na identificação de padrões de gastos que possam indicar o descumprimento de normas legais ou o uso inadequado de recursos públicos. Como as bases de dados governamentais raramente possuem rótulos indicando previamente quais portadores são anômalos, técnicas de aprendizado de máquina não supervisionado se mostram particularmente adequadas para esse tipo de análise.

Nesse contexto, o presente projeto tem como objetivo realizar uma análise sistemática e automatizada das despesas efetuadas por meio do CPGF entre os anos de 2022 e 2026. A proposta consiste em aplicar técnicas de mineração de dados a conjuntos de dados públicos, buscando transformar grandes volumes de registros financeiros em informações que possam auxiliar no monitoramento e na fiscalização dos gastos governamentais. O objetivo central é identificar padrões financeiros incomuns que possam indicar possíveis irregularidades ou uso indevido de recursos públicos.

Para isso, foi adotado um pipeline analítico dividido em três etapas principais: preparação inicial dos dados, exploração das informações e refinamento final dos resultados. Na etapa inicial, os dados passam por processos de limpeza, ajuste e padronização para normalizar os valores monetários. Em seguida, são aplicados algoritmos de análise como HDBSCAN e K-Means, que ajudam a identificar agrupamentos naturais nos dados e a detectar portadores que se desviam significativamente dos padrões de comportamento considerados normais. Espera-se que os resultados obtidos contribuam para tornar o

processo de auditoria mais eficiente, reduzindo a necessidade de análises manuais demoradas e fortalecendo a transparência na gestão dos recursos públicos.

2. Materiais e Métodos

O conjunto de dados utilizado neste estudo foi obtido a partir do Portal da Transparência do Governo Federal, contendo registros detalhados de despesas realizadas por meio do Cartão de Pagamento do Governo Federal (CPGF). Esse conjunto de dados é composto por diversos atributos que possibilitam análises tanto em nível agregado quanto individual, permitindo examinar a estrutura administrativa responsável pelos gastos públicos. Entre as variáveis disponíveis, destacam-se CÓDIGO e NOME DO ÓRGÃO SUPERIOR, CÓDIGO e NOME DO ÓRGÃO EXECUTOR, e CÓDIGO e NOME DA UNIDADE GESTORA, que possibilitam identificar a hierarquia institucional envolvida na execução das despesas.

Além disso, o conjunto de dados inclui informações que garantem a rastreabilidade dos portadores, como os campos ANO e MÊS DA FATURA, CPF e NOME DO PORTADOR DO CARTÃO, bem como CPF/CNPJ e NOME DO FAVORECIDO, permitindo identificar tanto os responsáveis pelas transações quanto os destinatários dos pagamentos. Informações operacionais relevantes também são fornecidas pelos atributos TRANSAÇÃO, DATA DA TRANSAÇÃO e VALOR DA TRANSAÇÃO, sendo este último o principal indicador quantitativo utilizado nas análises, especialmente para o cálculo de variações, identificação de padrões e detecção de possíveis comportamentos anômalos.

A pesquisa é conduzida utilizando um pipeline modular de mineração de dados dividido em três etapas, implementado em Python 3.10+. A principal fonte de dados consiste em arquivos CSV brutos provenientes do Portal da Transparência, contendo transações mensalmente do CPGF entre os anos de 2022 e 2026. O ambiente de desenvolvimento foi configurado por meio de um ambiente virtual, responsável por gerenciar as dependências listadas no arquivo requirements.txt, incluindo o uso de Jupyter Notebooks para execução das etapas do projeto.

2.1. Tarefa de Mineração

Do ponto de vista técnico, o projeto é classificado como uma tarefa de Detecção de Outliers, fundamentada em Aprendizado Não Supervisionado. A abordagem utiliza técnicas de Clusterização para diferenciar comportamentos transacionais considerados normais de registros excepcionais, sem a necessidade de rótulos prévios indicando fraudes.

Em vez de buscar assinaturas conhecidas de crimes ou irregularidades, o sistema modela estatisticamente o comportamento considerado “normal” da maioria dos registros. Qualquer ponto de dados que apresente um desvio significativo dessa estrutura densa de normalidade é isolado como uma anomalia. Essa estratégia é essencial para identificar novos padrões de irregularidades financeiras que poderiam passar despercebidos por sistemas tradicionais baseados apenas em regras fixas.

2.2. Pipeline de Mineração de Dados

O projeto está organizado em um pipeline modular de três etapas, em que cada fase é implementada em um Jupyter Notebook específico, localizado no diretório src/.

Etapa 1 - Pré-Processamento e Agregação: Nesta fase, realizada no notebook 01_pre_processamento.ipynb, os dados brutos do Portal da Transparência passam por uma limpeza para tratamento de valores ausentes e inconsistências. O diferencial desta etapa é a agregação dos dados por CPF e Nome do Portador, transformando a base de transações individuais em um perfil consolidado de gastos por cliente. Ao final, são gerados dois arquivos: cpgf_limpo.csv (com dados agregados e tratados) e cpgf_normalizado.csv, onde os atributos financeiros (como valor total e frequência) passam por uma normalização Z-Score para permitir a comparação estatística entre diferentes perfis.

Etapa 2 - Mineração de Dados (Detecção de Outliers): Utilizando a base normalizada, esta etapa aplica algoritmos de aprendizado não supervisionado, especificamente o K-Means e o HDBSCAN. O objetivo é modelar o comportamento de um "portador padrão" e identificar agrupamentos naturais de gastos. Clientes que apresentam comportamentos que se desviam significativamente da densidade desses grupos (distância elevada dos centroides no K-Means ou classificados como ruído no HDBSCAN) são isolados como anomalias de perfil

Etapa 3 - Pós-Processamento e Interpretação: A última fase do pipeline foca no refinamento dos resultados. Aqui, os portadores sinalizados como anômalos são analisados visualmente e estatisticamente para identificar as causas do desvio (ex: volume de gastos incompatível com a média ou frequência de uso atípica). O resultado final é a geração de uma lista de clientes prioritários para auditoria, transformando dados complexos em informações acionáveis para a fiscalização governamental.

2.3. Estrutura do Repositório do Projeto

O repositório foi organizado de forma a facilitar a separação clara entre dados brutos, código-fonte e documentação final.

dados/: reservado para os arquivos CSV brutos do CPGF. Devido às limitações de tamanho de arquivos no GitHub (arquivos maiores que 20 MB), a pasta inclui o arquivo link_acesso_dados.txt, contendo o link externo necessário para download dos dados.

src/: contém os Jupyter Notebooks responsáveis pela implementação do pipeline de mineração de dados em três etapas.

relatorio/: contém o relatório final do projeto, composto por um documento técnico completo de 10 páginas.

requirements.txt: lista todas as bibliotecas Python e dependências do ambiente utilizadas no projeto.

README.md: fornece informações gerais sobre o projeto e instruções rápidas para execução.

3. Resultados Experimentais

A fase experimental foi conduzida utilizando o pipeline de mineração de dados implementado em Python, aplicando os algoritmos HDBSCAN e K-Means aos dados consolidados do Cartão de Pagamento do Governo Federal (CPGF). Diferente de abordagens tradicionais que buscam erros em notas fiscais únicas, esta experimentação focou na modelagem do comportamento histórico do portador do cartão.

3.1. Metodologia de Agrupamento e Preparação de Perfis por Portador

Para viabilizar a detecção de desvios de conduta, realizou-se uma reengenharia de atributos voltada à análise de séries temporais por CPF. O objetivo foi transitar da análise de transações atomizadas para a construção de perfis comportamentais de portadores (CLIENTES). A agregação de dados utilizou as chaves identificadoras CPF e NOME DO PORTADOR DO CARTÃO, permitindo uma visão estratificada do uso do Cartão de Pagamento do Governo Federal (CPGF) entre 2022 e 2026.

A preparação dos perfis envolveu a consolidação de atributos financeiros e contextuais, fundamentais para caracterizar a habitualidade ou a excepcionalidade do gasto:

- Agregação Estatística de Valores: Para cada CPF, foram calculadas métricas de centralidade e volume, especificamente SUM(VALOR) para volume total, COUNT(TRANSAÇÕES) para frequência/folego operacional e MEAN(VALOR) para o ticket médio por transação.
- Contextualização Hierárquica e de Destino: A diversidade de gastos foi mapeada através dos atributos ÓRGÃO SUPERIOR, ÓRGÃO EXECUTOR e a capilaridade de favorecidos (CPF/CNPJ e NOME DO FAVORECIDO), permitindo identificar se o perfil de consumo está restrito a fornecedores específicos ou se apresenta dispersão incomum.
- Normalização Z-Score: Aplicou-se a normalização Z-Score sobre os dados agregados para transformar os atributos contínuos em uma escala com média zero e desvio padrão um. Este procedimento é técnico-cientificamente necessário para garantir que diferentes ordens de grandeza de gastos sejam processadas sem viés pelos algoritmos de clusterização, permitindo que o modelo identifique "distâncias" estatísticas (outliers) de forma equânime, independentemente do teto orçamentário da unidade gestora.

3.2 Aplicação dos Algoritmos K-Means e HDBSCAN

A mineração de dados foi executada sobre o conjunto processado cpgf_normalizado.csv, adotando uma estratégia híbrida de aprendizado não supervisionado:

- K-Means: Utilizado para particionar os portadores em grupos baseados na proximidade dos centroides. Para mitigar o risco de ótimos locais, empregou-se o método de inicialização K-Means++ (Bradley & Fayyad, 1998) e o Método do Cotovelo (Elbow Method, conforme Bholowalia & Kumar, 2014) para fundamentar a escolha do número ideal de k clusters, assegurando a convergência do modelo para a estrutura principal da massa de dados.

- HDBSCAN (High-Dimensional Density-Based Spatial Clustering of Applications with Noise): Aplicado como o mecanismo primário para o isolamento de anomalias. Diferente do K-Means, o HDBSCAN não força a inclusão de todos os pontos em clusters; ele utiliza critérios de densidade de vizinhança para identificar pontos que não possuem "alcançabilidade de densidade" em relação aos agrupamentos estáveis.

- Diferenciação Técnica: Os clusters densos capturam o "comportamento densamente normal", que reflete os padrões de execução orçamentária seguidos pela vasta maioria dos servidores. Em contrapartida, o HDBSCAN classifica tecnicamente como "ruído" os perfis que habitam zonas de baixa densidade, isolando-os como outliers que se desviam da morfologia estatística esperada para o CPGF.

Para determinar o número ideal de perfis de portadores (clusters), aplicou-se o Método do Cotovelo (Elbow Method). O gráfico demonstra uma redução acentuada na Soma dos Erros Quadráticos (SSE) até o valor de K=3, ponto a partir do qual a melhoria na coesão dos grupos se torna marginal, definindo a estrutura base de agrupamento dos clientes.

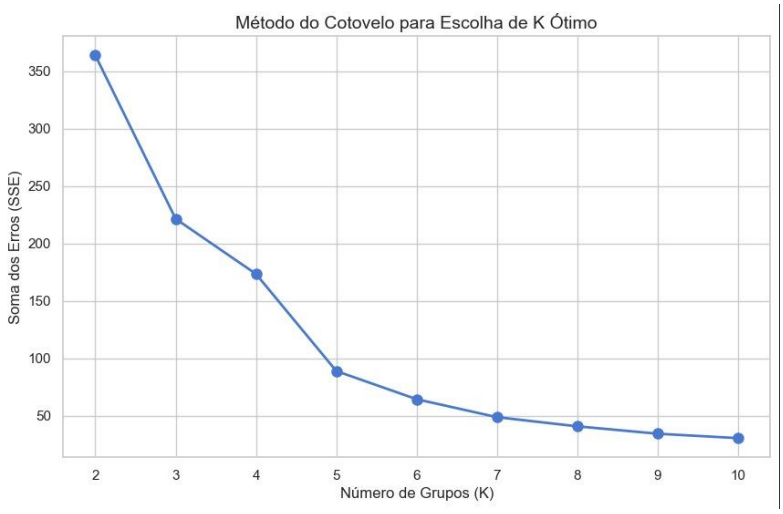

Gráfico 1 - Método do Cotovelo

A validação da separação entre os perfis de portadores foi realizada através do Silhueta. A distribuição bimodal apresentada indica que, enquanto uma massa significativa de portadores possui alta coesão em seus grupos (valores próximos a 0.75), existe um conjunto de clientes com scores baixos ou negativos, sinalizando indivíduos que não se encaixam bem em nenhum padrão e são candidatos a outliers.

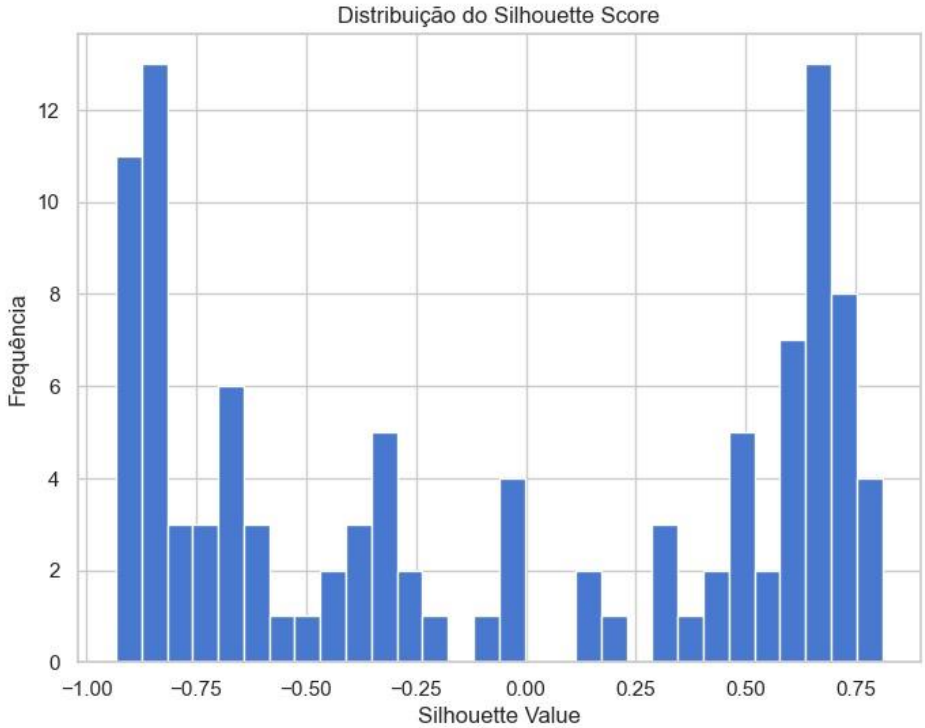

Gráfico 2 – Valor de Silhueta

3.3. Análise de Resultados e Detecção de Outliers

Utilizou-se a densidade do score de outliers do HDBSCAN para definir o rigor da auditoria. Estabeleceu-se um threshold de 0.75; portadores localizados na 'Cauda Longa' do gráfico (à direita da linha vermelha) apresentam comportamentos de gasto severamente divergentes da massa de dados e foram classificados como alvos prioritários.

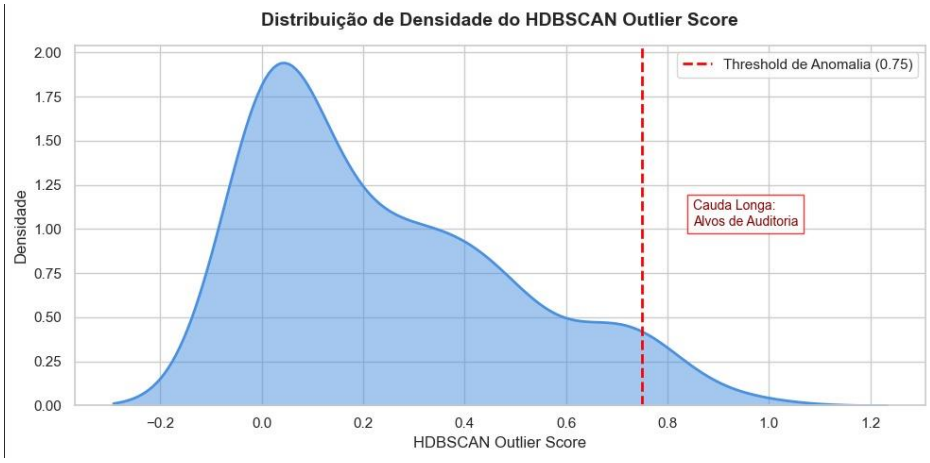

Gráfico 3 - Método do Cotovelo

A análise comparativa entre K-Means e HDBSCAN permite visualizar a dispersão dos portadores em relação ao volume total gasto e à quantidade de transações, especificamente para a Secretaria de Administração/PR. Os pontos marcados com um 'X' vermelho representam o Top 10 de portadores anômalos, evidenciando indivíduos que movimentam volumes financeiros desproporcionais ou possuem frequências de uso atípicas.

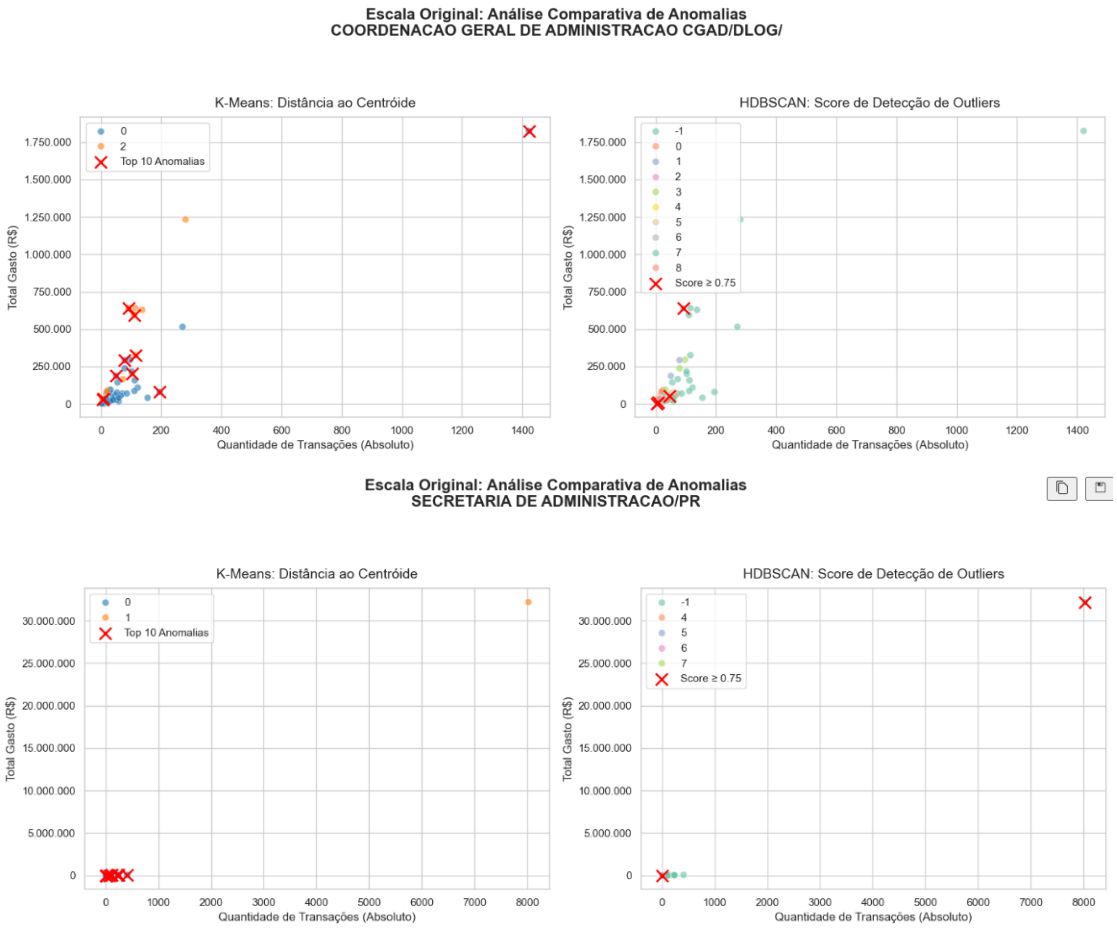

Gráfico 4 - Análise comparativa entre os algoritmos K-means e HDBSCAN

Ao agregar as anomalias por unidade administrativa, observa-se que a Secretaria de Administração/PR concentra o maior volume financeiro vinculado a portadores com scores de anomalia elevados, superando R$ 30 milhões em despesas sinalizadas pelo sistema.

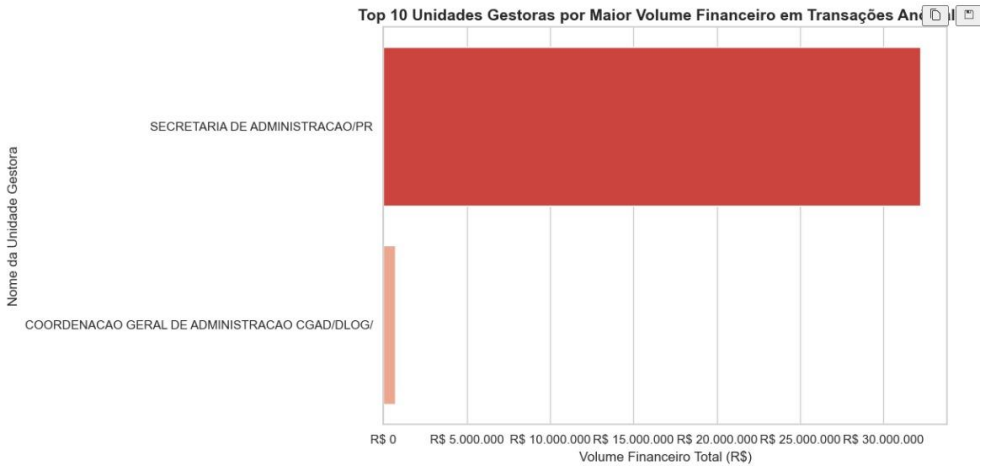

Gráfico 5 – Unidades gastadoras por volume financeiro

4. Considerações Finais

4.1. Síntese dos Achados e Eficácia da Mineração

A utilização de aprendizado não supervisionado mostrou-se a abordagem técnica definitiva diante da ausência de rótulos prévios de irregularidades nas bases do Portal da Transparência. A metodologia de reengenharia de atributos por CPF, combinada com a normalização Z-Score, permitiu que o sistema modelasse a "assinatura de normalidade" dos gastos públicos de forma autônoma. Os resultados demonstram que a análise de perfis agregados é superior à análise de transações isoladas para revelar comportamentos que, embora individualmente pareçam lícitos, compõem um quadro de anomalia sistemática no longo prazo.

4.2. Contribuição para a Fiscalização e Transparência Pública

A implementação desta metodologia oferece contribuições estratégicas para o controle governamental:

- Automatização da triagem: Processamento célere de volumes massivos de dados, permitindo a análise de todo o histórico do CPGF (2022-2026).

- Otimização de Recursos de Auditoria: Redução da carga de trabalho em auditorias manuais exaustivas, direcionando o esforço humano para perfis com altos índices de desvio estatístico.

- Suporte ao Controle Social: Transformação de dados brutos e complexos em indicadores de risco objetivos, fortalecendo a transparência e a prestação de contas à sociedade.

4.3. Identificação de Alvos de Alto Impacto

A eficácia do modelo é demonstrada pela detecção de casos de extrema relevância financeira e administrativa. O exemplo mais crítico identificado foi o alvo "SIGILOSO - SECRETARIA DE ADMINISTRACAO/PR", que obteve um Score de Anomalia de 0.9399. Este cliente movimentou um volume total de R$32.195.141,94,com gastos individuais recorrentes que ultrapass a marca de R$ 200 mil por operação. Outro caso relevante envolve um portador (Score 0.7884) que movimentou mais de R$ 640 mil em despesas cujos nomes dos favorecidos constam como "SEM INFORMACAO", evidenciando uma falha na transparência que o sistema foi capaz de sinalizar como risco elevado.

```
→ ALVO: SIGILOSO - SECRETARIA DE ADMINISTRACAO/PR | UNIDADE GESTORA: SECRETARIA DE ADMINISTRACAO/PR
  Score de Anomalia (HDBSCAN): 0.9399
  Volume Total Envolvido nas Transações: R$ 32.195.141,94
  Top 5 Maiores Gastos Individuais:
```

	DATA TRANSAÇÃO	NOME FAVORECIDO	VALOR TRANSAÇÃO
1	2024-01-05	Sigiloso	R$ 207.953,60
2	2024-01-07	Sigiloso	R$ 196.690,82
3	2023-01-06	Sigiloso	R$ 169.290,20
4	2024-01-04	Sigiloso	R$ 155.965,19
5	2023-01-08	Sigiloso	R$ 151.686,08

```
--------------------------------------------------------------------------------
→ ALVO: ***.152.124-** | UNIDADE GESTORA: COORDENACAO GERAL DE ADMINISTRACAO CGAD/DLOG/
  Score de Anomalia (HDBSCAN): 0.7884
  Volume Total Envolvido nas Transações: R$ 640.432,63
  Top 5 Maiores Gastos Individuais:
```

	DATA TRANSAÇÃO	NOME FAVORECIDO	VALOR TRANSAÇÃO
1	2024-10-17	SEM INFORMACAO	R$ 122.038,19
2	2024-09-17	SEM INFORMACAO	R$ 103.864,77
3	2024-10-24	SEM INFORMACAO	R$ 52.812,38
4	2024-06-24	SEM INFORMACAO	R$ 37.813,52
5	2024-09-20	SEM INFORMACAO	R$ 28.750,52

Imagem 1 – Top 5 Maiores Gastos Individuais por Unidade Gestora

4.4. Padrões de Fragmentação e Transações Atípicas

Além do volume financeiro bruto, o sistema isolou comportamentos estatisticamente improváveis baseados na natureza e frequência dos gastos: Na Imagem 2 - Transações Anômalas, foram identificados portadores com scores superiores a 0.75 cujos gastos são destinados a favorecidos identificados como "NAO SE APLICA" ou a estabelecimentos que fogem ao padrão administrativo esperado, como estacionamentos. Estes casos demonstram como o modelo captura a falta de clareza nos registros governamentais.

```
→ ALVO: ***.914.641-** | UNIDADE GESTORA: COORDENACAO GERAL DE ADMINISTRACAO CGAD/DLOG/
  Score de Anomalia (HDBSCAN): 0.7634
  Volume Total Envolvido nas Transações: R$ 2.900,00
  Top 5 Maiores Gastos Individuais:
```

	DATA TRANSAÇÃO	NOME FAVORECIDO	VALOR TRANSAÇÃO
1	2024-02-22	NAO SE APLICA	R$ 1.000,00
2	2024-03-06	NAO SE APLICA	R$ 1.000,00
3	2024-03-01	CW PARK ESTACIONAMENTOS LTDA	R$ 900,00

```
--------------------------------------------------------------------------------
→ ALVO: ***.920.171-** | UNIDADE GESTORA: SECRETARIA DE ADMINISTRACAO/PR
  Score de Anomalia (HDBSCAN): 0.7634
  Volume Total Envolvido nas Transações: R$ 850,87
  Top 5 Maiores Gastos Individuais:
```

	DATA TRANSAÇÃO	NOME FAVORECIDO	VALOR TRANSAÇÃO
1	2023-07-14	SEM INFORMACAO	R$ 850,87

```
--------------------------------------------------------------------------------
→ ALVO: ***.424.058-** | UNIDADE GESTORA: COORDENACAO GERAL DE ADMINISTRACAO CGAD/DLOG/
  Score de Anomalia (HDBSCAN): 0.7564
  Volume Total Envolvido nas Transações: R$ 51.262,38
  Top 5 Maiores Gastos Individuais:
```

	DATA TRANSAÇÃO	NOME FAVORECIDO	VALOR TRANSAÇÃO
1	2021-12-01	NAO SE APLICA	R$ 1.385,02
2	2021-11-29	NAO SE APLICA	R$ 1.342,17
3	2021-11-30	NAO SE APLICA	R$ 1.341,77
4	2021-11-25	NAO SE APLICA	R$ 1.327,29
5	2021-11-26	NAO SE APLICA	R$ 1.317,95

Imagem 2 – Transações Anômalas

A Imagem 3 - ilustra um padrão clássico de fragmentação de despesas. O algoritmo sinalizou um portador (Score 0.7502) que realizou múltiplas transações consecutivas de exatos R$ 1.000,00 para favorecidos não identificados. A detecção automática desse comportamento repetitivo reitera a precisão do sistema em identificar indícios de uso indevido que poderiam passar despercebidos em análises manuais.

```
➜ ALVO: ***.167.609-** | UNIDADE GESTORA: COORDENACAO GERAL DE ADMINISTRACAO CGAD/DLOG/
  Score de Anomalia (HDBSCAN): 0.7502
  Volume Total Envolvido nas Transações: R$ 8.000,00
  Top 5 Maiores Gastos Individuais:
```

	DATA TRANSAÇÃO	NOME FAVORECIDO	VALOR TRANSAÇÃO
1	2022-09-15	NAO SE APLICA	R$ 1.000,00
2	2022-09-12	NAO SE APLICA	R$ 1.000,00
3	2022-08-30	NAO SE APLICA	R$ 1.000,00
4	2022-10-19	NAO SE APLICA	R$ 1.000,00
5	2022-10-11	NAO SE APLICA	R$ 1.000,00

Imagem 3 – Múltiplas Transações de Valor Similar

4.5. Recomendações para Trabalhos Futuros

Para a evolução deste pipeline de detecção, recomenda-se a integração de novos atributos contextuais, como a natureza econômica da despesa, para refinar os clusters por setor administrativo. Dada a natureza contínua dos dados até 2026, é imperativo que o modelo seja submetido a processos de re-normalização periódica para mitigar o fenômeno de data drift (deriva de dados), garantindo que a definição de "normalidade" evolua conforme as mudanças nas políticas de gastos públicos. Este relatório reafirma a viabilidade da ciência de dados como ferramenta de elite na fiscalização, promovendo uma gestão de recursos públicos pautada pela eficiência, rigor estatístico e transparência absoluta.

5. Referências

Este estudo tem como base metodológica a pesquisa pioneira de Nunes et al. (2021), intitulada “Detecção de Anomalias em Cartões de Pagamento do Governo Federal Brasileiro por Meio de Técnicas de Aprendizado Não Supervisionado”. O trabalho dos autores demonstra que algoritmos de aprendizado não supervisionado podem detectar de forma eficaz despesas atípicas dentro do sistema do Cartão de Pagamento do Governo Federal (CPGF), sem a necessidade de rotulação prévia dos dados por especialistas.

Com base nisso, a presente pesquisa se fundamenta no arcabouço proposto pelo estudo original, o qual é ampliado ao transformar dados brutos provenientes do Portal da Transparência em indicadores claros de potenciais irregularidades.

Referências:

1. Nunes, B., Colliri, T., Lauretto, M., Liu, W., Zhao, L. (2021). Detecção de anomalias em cartões de compras do governo federal brasileiro por meio de técnicas de aprendizado não supervisionado. In: Britto, A., Valdivia Delgado, K. (eds) Sistemas Inteligentes. BRACIS 2021. Lecture Notes in Computer Science(), vol 13074. Springer, Cham. https://doi.org/10.1007/978-3-030-91699-2_2
2. de Andrade, P.H.M.A., Meira, W., Cerqueira, B., Cruz, G.: Auditing government purchases with a multicriteria anomaly detection strategy. Journal of Information and Data Management 11(1) (2020)
3. Bholowalia, P., Kumar, A.: EBK-means: A clustering technique based on elbow method and k-means in WSN. International Journal of Computer Applications 105(9)

(2014)
4. Bradley, P.S., Fayyad, U.M.: Refining initial points for k-means clustering. In: ICML. vol. 98, pp. 91–99. Citeseer (1998)
5. Colliri, T., Zhao, L.: Stock market trend detection and automatic decision-making through a network-based classification model. Natural Computing pp. 1–14 (2021)
6. Day, W.H., Edelsbrunner, H.: Efficient algorithms for agglomerative hierarchical clustering methods. Journal of Classification 1(1), 7–24 (1984)
7. Li, J., Di, S., Shen, Y., Chen, L.: Fluxev: A fast and effective unsupervised framework for time-series anomaly detection. In: Proceedings of the 14th ACM International Conference on Web Search and Data Mining. pp. 824–832 (2021)
8. Likas, A., Vlassis, N., Verbeek, J.J.: The global k-means clustering algorithm. Pattern recognition 36(2), 451–461 (2003)
9. Rezapour, M.: Anomaly detection using unsupervised methods: credit card fraud case study. Int J Adv Comput Sci Appl 10(11) (2019)
10. da Uniao, B.C.G.: Portal da transparencia. Gastos por cartoes de pagamento. www.portaltransparencia.gov.br/cartoes?ano=2022. Acesso em: 8 mar. 2026.
11. BITURUNA. GitHub - bituruna/cpgf-anomaly-detection-md. Disponível em: https://github.com/bituruna/cpgf-anomaly-detection-md. Acesso em: 8 mar. 2026.